

Imitando un algoritmo de trayectoria para el WTAP

Una red de capas densas (MLP) que aprende a asignar armas a objetivos imitando paso a paso a un experto óptimo

[Nombre(s) del grupo]


Optimización combinatoria · 2026

El problema: Weapon-Target Assignment

$W = 10$ armas y $T = 8$ objetivos. El objetivo j vale V_j y el arma i lo destruye con probabilidad p_{ij} . Cada arma se asigna a un solo objetivo.

$$\min_x f(x) = \sum_{j=1}^T V_j \prod_{i=1}^W (1 - p_{ij})^{x_{ij}}$$

valor esperado que sobrevive (se minimiza)



NP-hard

objetivo no lineal

$8^{10} \approx 10^9$

asignaciones posibles

Constructivo

1 arma por paso, orden fijo

Estado y acción: ¿a qué objetivo va la próxima arma?

Las armas se asignan en orden fijo (0, 1, ..., 9); en cada paso la red elige el objetivo de la arma actual

ACCIÓN → 8 clases

("constructive", j): asignar la arma actual al objetivo j. El target de la red es el índice j.


ESTADO → matriz 8 × 15

Fila j = objetivo j durante todo el episodio; 15 características que describen al objetivo y su situación en el paso actual.

¿QUÉ MIRA LA RED?

Actuales (0–9): valor, prob. de sobrevivir q_j , efectividad de la arma actual p_{tj} , **ganancia marginal** $V_j \cdot q_j \cdot p_{tj}$, armas ya asignadas...

Anticipación (10–14): ¿hay una arma futura mejor para j? (arrepentimiento, rango) y cómo quedaría j si se completa con MMR.



Ejemplo real: estado con 4 armas asignadas (arma actual = 4).

El recuadro rojo marca el objetivo que elige el experto; la línea blanca separa las características actuales de las de anticipación.

Todo está normalizado (valores ÷ máximo de la instancia).

→ **Ninguna característica sola da la respuesta: la red aprende a combinarlas.**

¿A qué objetivo iría la arma 4?

Greedy (mayor ganancia)

o1

Completar con MMR


o5

Experto (lo que se imita)


o3

Datos de imitación y modelo

El experto resuelve cada instancia; su solución se reproduce paso a paso para obtener pares (estado → acción)





Modelo: MLP de capas densas (PyTorch)



Entrenamiento: entropía cruzada · Adam (lr = 0,001) · batch 256 · **early stopping** (patience 10, restaura la mejor época). En el rollout, la red reemplaza a la función de evaluación del GreedyAgent de la librería del curso.

Entrenamiento: loss y accuracy por época

Early stopping detiene el entrenamiento cuando la pérdida de validación deja de mejorar



85,8%

accuracy de validación

decisiones iguales al experto

época 27

mejor época

se detuvo en la época 37

76,7%



acc. modelo base

sin anticipación

Lectura: la pérdida de entrenamiento sigue bajando mientras la de validación se estanca → comienza el sobreajuste y se restauran los pesos de la mejor época.

Experimentos: ¿qué necesita saber la red?

Ablación de características e hiperparámetros, evaluando accuracy Y calidad del rollout (100 instancias de validación)



A · 10 feats (sin anticipación) | B · 12 feats (+ comparativas) | C · 15 feats, [512,256,128], dp 0.2 | D · 15 feats, [256,256], sin dropout | E · 15 feats, [512,512,256], dp 0.3

Config.	Características	Red	Acc. val	Gap rollout
A	10 (sin anticipación)	[512,256,128], dp 0,2	76,7%	13,3%
B	12 (+ comparativas)	[512,256,128], dp 0,2	82,4%	10,5%
C	15 (completas)	[512,256,128], dp 0,2	86,0%	4,2%
D	15 (completas)	[256,256], sin dropout	85,6%	6,5%
E	15 (completas)	[512,512,256], dp 0,3	85,8%	4,0%

CONCLUSIÓN

Las características de anticipación son lo que más importa: el gap baja de **13,3%** a **4,0%** (MMR: 6,9%). Cambiar la red o el Dropout influye menos, y con igual accuracy el gap puede variar: hay que evaluar el rollout.

Resultados en 50 instancias nuevas

Gap promedio respecto al experto (menor es mejor) · mismo agente greedy; solo cambia quién evalúa las acciones

4,4%

Modelo MLP

costo medio 48,3 · óptimo en 20%

7,7%

MMR (clásica)

costo medio 49,8 · óptimo en 6%

49,3%

Greedy secuencial


costo medio 68,4 · óptimo en 0%

0,0%


Experto (ILS)

costo medio 46,3 · óptimo en 100%


Distribución de costos en 50 instancias nuevas



Gap promedio (menor es mejor)



Por instancia: bajo la diagonal gana el modelo



Conclusión: La MLP gana a MMR en 60% de las instancias (empata en 14%) y reduce el gap del greedy secuencial de 49,3% a 4,4%, respetando el mismo orden de armas. Sin las características de anticipación el modelo queda en 9,9%: lo que la red ve del estado es clave.